

CAHIER DES CHARGES FONCTIONNEL ET TECHNIQUE

MailFind

Bibliothèque de contacts professionnels d'entreprises : collecte, enrichissement, vérification et export, avec intégration à Campaign Mailer.

Version	1.0
Date	22 septembre 2026
Auteur et propriétaire	Daniel Nagoloum Talla
Statut	Référence pour le développement du MVP
Produit lié	Campaign Mailer

Historique des versions

Version	Date	Objet
1.0	22 septembre 2026	Première version de référence

Sommaire

1. Présentation du projet
2. Objectifs et indicateurs de réussite
3. Périmètre
4. Utilisateurs et cas d'usage
5. Parcours principal
6. Exigences fonctionnelles
7. Exigences non fonctionnelles
8. Architecture technique
9. Modèle de données
10. Sécurité
11. Conformité juridique et protection des données
12. Exploitation et observabilité
13. Tests et recette
14. Planning et jalons
15. Risques
16. Glossaire
17. Annexes

1. Présentation du projet

1.1 Contexte

Une personne qui cherche une alternance, un stage ou des clients passe l'essentiel de son temps à trouver à qui écrire. Pour chaque entreprise, elle ouvre le site, cherche une page de contact ou de recrutement, relève une adresse quand il y en a une, et recommence. Sur une liste de 200 entreprises, ce travail prend plusieurs jours et produit un tableur sans source, sans date et sans indication de fiabilité.

Campaign Mailer, développé par le même auteur, résout l'étape suivante : envoyer un message personnalisé à chaque contact depuis le compte Gmail de l'utilisateur, à un rythme maîtrisé. Il suppose une liste de contacts déjà constituée. MailFind produit cette liste.

1.2 Le produit

MailFind est une application web qui transforme une liste d'entreprises en une bibliothèque d'adresses email professionnelles vérifiées, classées par entreprise et prêtes à l'envoi.

L'utilisateur importe un fichier CSV contenant des noms d'entreprises, des domaines, des sites web ou des pages carrières. Pour chaque ligne, MailFind identifie l'entreprise et son domaine officiel, explore les pages publiques pertinentes de son site, interroge des fournisseurs d'enrichissement disposant d'une API officielle, génère les adresses de rôle probables, vérifie chaque adresse obtenue et enregistre sa source. Le résultat s'exporte en CSV, XLSX ou JSON, toujours classé par entreprise, ou s'envoie directement dans Campaign Mailer sous forme de campagne en brouillon.

MailFind expose aussi une API publique qui permet à d'autres applications de rechercher des adresses pour un domaine, de lancer une vérification et de récupérer les résultats.

1.3 Ce qui distingue MailFind

- **Chaque adresse a une preuve.** L'URL où elle a été trouvée, la méthode, la date et le fournisseur sont conservés et affichés. Une adresse sans source n'existe pas dans MailFind.
- **La vérification est un statut, pas une promesse.** MailFind distingue une adresse trouvée, une adresse déduite et une adresse vérifiée, et ne présente jamais un résultat incertain comme certain.
- **Plusieurs sources, un seul résultat.** Le site officiel d'abord, les fournisseurs ensuite, la déduction en dernier. Une adresse confirmée par plusieurs sources monte en confiance.
- **Le coût est maîtrisé.** Chaque appel payant est compté, mis en cache et plafonné. L'utilisateur voit l'estimation avant de lancer un traitement.
- **La sortie est directement utilisable.** Les exports sont structurés par entreprise et le format Campaign Mailer s'importe sans retouche.

2. Objectifs et indicateurs de réussite

2.1 Objectifs

N°	Objectif
O1	Réduire de plusieurs jours à quelques minutes la constitution d'une liste de contacts pour 200 entreprises.
O2	Trouver au moins une adresse exploitable pour la majorité des entreprises disposant d'un site web.
O3	Ne jamais exporter comme vérifiée une adresse qui ne l'est pas.
O4	Conserver la provenance de chaque donnée, pour la transparence et la conformité.
O5	Envoyer les résultats dans Campaign Mailer sans export manuel.
O6	Offrir une API stable et documentée pour la recherche et la vérification d'adresses.
O7	Maîtriser le coût des fournisseurs payants, par utilisateur et par traitement.

2.2 Indicateurs mesurés

Indicateur	Cible au lancement de la bêta
Taux de couverture : entreprises avec au moins une adresse <code>valid</code> ou <code>risky</code> , parmi celles qui ont un site accessible	70 % ou plus
Taux de rebond constaté dans Campaign Mailer sur des adresses <code>valid</code> exportées par MailFind	moins de 3 %
Durée de traitement d'un import de 100 entreprises en profondeur standard	moins de 15 minutes
Adresses exportées sans source	0
Latence de l'API en lecture (95e centile)	moins de 300 ms
Coût fournisseur moyen par entreprise traitée	affiché, et sous le plafond fixé en Phase 0

3. Périmètre

3.1 Inclus dans le MVP

- Comptes utilisateurs avec connexion Google (identité uniquement, sans accès à la messagerie).
- Import CSV avec détection et correspondance des colonnes.
- Identification des entreprises et de leur domaine officiel.
- Collecte ciblée sur les pages publiques du site officiel.
- Interrogation d'au moins un fournisseur d'enrichissement (Hunter).
- Génération d'adresses de rôle candidates.
- Vérification locale (syntaxe, DNS, MX, domaines jetables, adresses de rôle) et vérification de boîte par un fournisseur.
- Score de confiance par adresse.
- Bibliothèque consultable, filtrable, avec actions en masse.
- Exports CSV, XLSX et JSON classés par entreprise, et format Campaign Mailer.
- Envoi direct vers Campaign Mailer.
- API publique v1 avec clés, documentation OpenAPI et webhooks.
- Quotas, compteur de crédits et estimation des coûts.
- Liste de suppression, suppression de données, journal d'audit.

3.2 Prévu après le MVP

- Recherche d'entreprises en langage naturel (« startups SaaS de moins de 200 personnes à Lyon qui recrutent des alternants »).
- Détection des offres d'emploi et d'alternance sur les pages carrières.
- Suivi des candidatures par entreprise (à contacter, contactée, réponse, entretien, refus).
- Rendu des sites construits en JavaScript par un navigateur sans interface.
- Espaces d'équipe partagés, rôles et facturation.
- Second fournisseur d'enrichissement et fournisseur spécialisé de vérification.

3.3 Hors périmètre

- Envoi d'emails. C'est le rôle de Campaign Mailer.
- Collecte sur des réseaux sociaux, des annuaires dont les conditions l'interdisent ou des pages derrière une authentification.
- Contournement d'une protection technique : CAPTCHA, masquage d'adresse, limitation de débit, blocage d'adresse IP.
- Revente ou partage de données entre utilisateurs.
- Constitution de profils de personnes. MailFind décrit des entreprises et leurs canaux de contact, pas des individus.

4. Utilisateurs et cas d'usage

4.1 Profils

Profil	Besoin principal
Candidat (alternance, stage, emploi)	Trouver l'adresse recrutement ou RH de 50 à 300 entreprises ciblées, puis écrire à chacune depuis Campaign Mailer.
Indépendant ou commercial	Constituer une liste de contacts génériques ou commerciaux pour une prospection B2B mesurée.
Recruteur ou chargé de relations entreprises	Tenir à jour les contacts d'un portefeuille d'entreprises partenaires.
Application tierce	Interroger MailFind par API pour obtenir ou vérifier des adresses. Campaign Mailer est la première.
Administrateur	Surveiller l'usage, les coûts, les erreurs et les fournisseurs.

4.2 Récits utilisateur principaux

N°	En tant que	Je veux	Afin de
U1	candidat	importer la liste des entreprises qui m'intéressent	ne pas chercher leurs adresses une par une
U2	candidat	voir en priorité les adresses recrutement et RH	écrire à la bonne personne
U3	utilisateur	savoir d'où vient chaque adresse et si elle est vérifiée	décider en connaissance de cause
U4	utilisateur	exporter les adresses classées par entreprise	les retravailler dans un tableur
U5	utilisateur de Campaign Mailer	envoyer ma sélection dans une nouvelle campagne	lancer mes envois sans ressaisie
U6	utilisateur	connaître le coût d'un traitement avant de le lancer	ne pas épuiser mes crédits par erreur
U7	développeur	appeler une API pour trouver et vérifier des adresses	intégrer MailFind à mon application
U8	utilisateur	supprimer une entreprise ou une adresse, définitivement	répondre à une demande d'effacement

5. Parcours principal : de l'import à l'export

La recherche des adresses est déclenchée par l'import d'un fichier CSV. Tout le traitement se fait en arrière-plan : l'utilisateur peut quitter la page et revenir, la progression est conservée.

Étape	Déclencheur	Comportement attendu
1. Téléversement	L'utilisateur dépose un fichier CSV	Le fichier est lu dans le navigateur. Encodage (UTF-8, Windows-1252) et séparateur (virgule, point-virgule, tabulation) sont détectés.
2. Correspondance des colonnes	Automatique, modifiable	Chaque colonne est rapprochée d'un champ connu (voir 6.2). L'utilisateur corrige si besoin.
3. Prévisualisation	Automatique	Les dix premières lignes s'affichent telles qu'elles seront traitées. Les lignes inexploitable sont signalées avec leur motif.
4. Paramètres	L'utilisateur choisit	Profondeur de collecte (rapide, standard, approfondie), types d'adresses recherchés (recrutement, RH, générique, commercial, presse), fournisseurs autorisés, étiquettes à appliquer.
5. Estimation	Automatique	Nombre d'entreprises, crédits fournisseurs estimés, durée estimée. Confirmation obligatoire au-delà du seuil fixé par l'utilisateur.
6. Normalisation	Lancement	Noms, domaines et URL sont nettoyés. Les doublons dans le fichier et avec la bibliothèque sont détectés.
7. Identification	Par entreprise	Le domaine officiel est confirmé ou recherché (voir 6.3).
8. Collecte web	Par entreprise	Les pages publiques pertinentes du site sont explorées (voir 6.4).
9. Enrichissement	Si le résultat est insuffisant	Les fournisseurs configurés sont interrogés dans l'ordre (voir 6.6).
10. Adresses candidates	Si aucun rôle recherché n'est trouvé	Les adresses de rôle probables sont générées (voir 6.5).
11. Vérification	Pour chaque adresse	Contrôles locaux, puis vérification de boîte selon les réglages (voir 6.7).
12. Classement et score	Pour chaque adresse	Type, score de confiance et rattachement à l'entreprise (voir 6.8 et 6.9).
13. Rapport	Fin de l'import	Entreprises traitées, adresses trouvées par statut, erreurs, crédits consommés. Notification dans l'application et par webhook.
14. Export ou envoi	L'utilisateur choisit	Export classé par entreprise ou envoi vers Campaign Mailer (voir 6.11 et 6.12).

6. Exigences fonctionnelles

Chaque exigence porte un identifiant. La priorité est notée **M** (indispensable au MVP), **S** (souhaitée au MVP) ou **P** (après le MVP).

6.1 Comptes et accès

Id	Exigence	Priorité
F-101	Connexion par Google avec les seules portées <code>openid</code> , <code>email</code> et <code>profile</code> . MailFind ne demande aucun accès à la messagerie.	M
F-102	Acceptation des conditions d'utilisation et de la politique de confidentialité à la première connexion, versionnées.	M
F-103	Chaque utilisateur a sa propre bibliothèque. Aucune donnée n'est visible d'un autre compte.	M
F-104	Page Compte : identité, consommation du mois, clés d'API, connexion à Campaign Mailer, export de toutes ses données, suppression du compte.	M
F-105	Espaces d'équipe avec rôles (propriétaire, membre, lecture seule).	P

6.2 Import CSV

Id	Exigence	Priorité
F-201	Formats acceptés : CSV et TSV, jusqu'à 5 000 lignes et 5 Mo par fichier.	M
F-202	Chaque ligne doit contenir au moins un nom d'entreprise, un domaine, une URL de site ou une URL de page carrières. Une ligne qui n'en contient aucun est écartée avec son motif.	M
F-203	Correspondance automatique des colonnes à partir des en-têtes usuels, en français et en anglais, modifiable par l'utilisateur.	M
F-204	Les colonnes non reconnues sont conservées comme attributs libres de l'entreprise et restituées à l'export.	S
F-205	Un import peut être annulé en cours. Les entreprises déjà traitées restent dans la bibliothèque.	M
F-206	Un import interrompu (redémarrage du service) reprend là où il s'était arrêté, sans refaire les étapes terminées ni consommer deux fois un crédit.	M
F-207	Import par l'API, en fichier ou en lignes JSON (voir 6.13).	M

Champs reconnus :

Champ	Obligatoire	En-têtes reconnus (exemples)	Exemple
<code>company_name</code>	un des quatre	entreprise, société, company, nom	Doctolib
<code>domain</code>	un des quatre	domaine, domain	doctolib.fr
<code>website_url</code>	un des quatre	site, site web, website, url	https://www.doctolib.fr
<code>careers_url</code>	un des quatre	carrières, recrutement, careers, jobs	https://careers.doctolib.fr

Champ	Obligatoire	En-têtes reconnus (exemples)	Exemple
city	non	ville, city	Paris
country	non	pays, country	France
siren	non	siren, siret	794598813
industry	non	secteur, industry	Santé, logiciel
contact_name	non	contact, nom du contact	Camille Martin
tags	non	étiquettes, tags	alternance;paris
notes	non	notes, commentaire	Candidature spontanée

6.3 Normalisation et identification des entreprises

Id	Exigence	Priorité
F-301	Normalisation des URL : protocole ajouté si absent, <code>www.</code> et chemins retirés pour obtenir le domaine, domaines internationalisés convertis en punycode.	M
F-302	Normalisation des noms : casse, espaces, accents et formes juridiques (SAS, SARL, SA, Inc., Ltd, GmbH) écartés pour la comparaison, conservés pour l'affichage.	M
F-303	Dédoublonnage par domaine, puis par SIREN, puis par nom normalisé et ville. Un doublon est rattaché à l'entreprise existante, jamais créé deux fois.	M
F-304	Quand seul le nom est fourni, recherche de l'entreprise dans l'API Recherche d'entreprises de l'État (France) pour obtenir SIREN, adresse, activité et tranche d'effectif.	M
F-305	Quand le domaine manque, recherche du site officiel par un fournisseur de recherche web disposant d'une API officielle. Le résultat est proposé avec un indice de confiance ; en dessous du seuil, l'entreprise passe en « domaine à confirmer » et l'utilisateur tranche.	M
F-306	Une page carrières hébergée chez un tiers (Welcome to the Jungle, Lever, Greenhouse, Teamtailor, Workable) est reconnue comme telle : elle n'est pas prise pour le domaine de l'entreprise.	M
F-307	L'utilisateur peut corriger le domaine d'une entreprise ; la collecte est alors relancée sur le bon domaine.	M

6.4 Moteur de collecte sur le site officiel

La collecte explore un petit nombre de pages ciblées. Elle ne parcourt jamais un site entier.

Id	Exigence	Priorité
F-401	Pages visitées, dans cet ordre : page d'accueil, pages dont le chemin ou le lien correspond à contact, contactez-nous, nous-contacter, a-propos, about, equipe, mentions-legales, legal, recrutement, carrieres, careers, jobs, rejoindre, presse, press. La page carrières fournie dans l'import est ajoutée.	M
F-402	Profondeur par niveau : rapide (accueil et page contact, 3 pages au plus), standard (liste F-401, 10 pages au plus), approfondie (liens internes de ces pages, 25 pages au plus).	M
F-403	Respect du fichier <code>robots.txt</code> (RFC 9309) pour l'agent de MailFind. Une page interdite n'est pas visitée.	M
F-404	Agent utilisateur explicite, identifiant MailFind et donnant une URL de contact et de retrait.	M

Id	Exigence	Priorité
F-405	Une requête à la fois par domaine, au moins une seconde entre deux requêtes sur le même domaine, délai d'expiration de 10 secondes, 2 Mo au plus par page, 2 redirections au plus hors du domaine.	M
F-406	Extraction des adresses : liens <code>mailto:</code> , texte visible, attributs, données structurées <code>schema.org</code> (JSON-LD, microdonnées), formes écrites courantes (<code>contact [at] domaine [point] fr</code> , <code>contact(at)domaine.fr</code>).	M
F-407	Aucune tentative de décoder une adresse volontairement masquée par un mécanisme de protection (chiffrement côté client, image, script de masquage). La page est notée « adresse masquée » et le formulaire de contact est proposé à la place.	M
F-408	Détection des formulaires de contact et des liens vers des pages carrières, conservés comme canaux alternatifs quand aucune adresse n'est publiée.	M
F-409	Relevé complémentaire : téléphone du standard, lien LinkedIn de l'entreprise, adresse postale publiée dans les mentions légales.	S
F-410	Filtrage des faux positifs : adresses d'exemple, adresses de prestataires (hébergeur, agence web, outil de formulaire), fichiers images nommés comme des adresses, domaines sans rapport avec l'entreprise sauf s'ils sont confirmés par les mentions légales.	M
F-411	Chaque adresse trouvée est enregistrée avec l'URL exacte de la page, la méthode d'extraction, un extrait du contexte (200 caractères au plus) et la date.	M
F-412	Les pages rendues uniquement par JavaScript sont signalées « contenu dynamique non analysé ».	M
F-413	Rendu de ces pages par un navigateur sans interface, sous quota.	P
F-414	Mise en cache des pages visitées pendant 7 jours : une seconde collecte sur le même domaine dans ce délai ne refait pas les requêtes.	S

6.5 Génération d'adresses candidates

Quand la collecte et les fournisseurs n'ont pas trouvé d'adresse du type recherché, MailFind propose les adresses de rôle les plus probables pour le domaine. Ces adresses sont des hypothèses : elles portent l'origine « déduite » et ne sont jamais exportées comme vérifiées sans vérification positive.

Id	Exigence	Priorité
F-501	Génération à partir d'une liste de préfixes de rôle par type (annexe D), dans l'ordre de fréquence observée.	M
F-502	Uniquement sur le domaine confirmé de l'entreprise, et seulement si ce domaine a des enregistrements MX.	M
F-503	Chaque candidate est vérifiée (6.7) avant d'apparaître dans les résultats. Une candidate <code>invalid</code> est écartée sans être montrée ; une candidate <code>unknown</code> ou <code>accept_all</code> apparaît avec la mention « non confirmée ».	M
F-504	Adresses nominatives (prenom.nom@) : générées seulement si l'utilisateur fournit lui-même le nom de la personne dans l'import, et seulement en suivant un format déjà observé sur le domaine (par exemple une adresse nominative trouvée sur le site ou fournie par un fournisseur). Jamais par combinaison de noms trouvés ailleurs.	S
F-505	Le nombre de candidates vérifiées par entreprise est plafonné (5 par défaut) pour contenir le coût de vérification.	M

6.6 Fournisseurs d'enrichissement

Id	Exigence	Priorité
F-601	Chaque fournisseur est un adaptateur derrière une interface commune (recherche par domaine, recherche nominative, vérification). Changer de fournisseur ne modifie aucun autre module.	M
F-602	Fournisseur de référence : Hunter (recherche par domaine, vérification). Second fournisseur possible : Snov.io. Fournisseur spécialisé de vérification possible : ZeroBounce ou NeverBounce.	M pour Hunter, P pour les autres
F-603	Ordre de repli par défaut : site officiel, puis Hunter, puis second fournisseur, puis adresses candidates. Un fournisseur n'est appelé que si les étapes précédentes n'ont pas trouvé d'adresse du type recherché.	M
F-604	Chaque réponse est mise en cache par domaine pendant 30 jours. Une seconde demande sur le même domaine dans ce délai ne consomme aucun crédit.	M
F-605	Les clés des fournisseurs sont celles de MailFind par défaut. Un utilisateur peut renseigner sa propre clé Hunter ; elle est chiffrée au repos et n'est jamais renvoyée par l'API.	S
F-606	Une erreur de fournisseur (quota, indisponibilité, clé invalide) n'arrête pas l'import : l'étape est marquée en échec avec son motif et la suite du repli continue.	M

6.7 Vérification avancée des adresses

La vérification produit un statut, un motif et une date. Elle ne garantit pas qu'un message sera lu, seulement qu'il a de bonnes chances d'être accepté.

Contrôles, du moins coûteux au plus coûteux :

Niveau	Contrôle	Réalisé par	Coût
1	Syntaxe selon un sous-ensemble strict de la RFC 5321, longueur, caractères, domaine internationalisé	MailFind	nul
2	Existence du domaine (DNS)	MailFind	nul
3	Enregistrements MX, ou A en repli comme le prévoit la norme ; domaine sans serveur de messagerie refusé	MailFind	nul
4	Domaine jetable, d'après une liste publique tenue à jour chaque semaine	MailFind	nul
5	Adresse de rôle (contact, rh, jobs) repérée et typée	MailFind	nul
6	Adresse sur une messagerie grand public (gmail.com, outlook.fr) signalée pour un usage professionnel	MailFind	nul
7	Suppression : adresse présente dans la liste de suppression de l'utilisateur ou de Campaign Mailer	MailFind	nul
8	Vérification de la boîte auprès du serveur de messagerie, et détection des domaines qui acceptent toute adresse	fournisseur	crédit

La vérification de boîte (niveau 8) est confiée à un fournisseur et n'est jamais faite depuis les serveurs de MailFind. Deux raisons : l'hébergeur bloque les ports SMTP sortants sur ses offres d'entrée de gamme, et sonder des serveurs de messagerie depuis l'adresse IP de l'application la ferait rapidement inscrire sur des listes de blocage.

Statuts normalisés :

Statut	Signification	Action par défaut à l'export et vers Campaign Mailer
<code>valid</code>	Le serveur de messagerie accepte cette adresse	Inclure
<code>accept_all</code>	Le domaine accepte toute adresse : impossible de confirmer celle-ci	Inclure si l'utilisateur l'autorise, signalée
<code>risky</code>	Adresse de rôle, messagerie grand public ou vérification partielle	Inclure si l'utilisateur l'autorise, signalée
<code>unknown</code>	Le serveur n'a pas répondu de façon exploitable	Exclure par défaut
<code>invalid</code>	Adresse inexistante ou domaine sans messagerie	Toujours exclure
<code>disposable</code>	Domaine jetable	Toujours exclure
<code>suppressed</code>	Adresse dans une liste de suppression	Toujours exclure, jamais réimportée
<code>unverified</code>	Pas encore vérifiée	Exclure des envois tant qu'elle n'est pas vérifiée

Id	Exigence	Priorité
F-701	Les niveaux 1 à 7 sont appliqués à toute adresse, à la découverte et à l'import.	M
F-702	Le niveau 8 est appliqué selon le réglage de l'import : jamais, adresses trouvées seulement, ou toutes (adresses candidates comprises).	M
F-703	Chaque vérification est enregistrée : statut, sous-statut du fournisseur, motif lisible, fournisseur, date. L'historique est conservé.	M
F-704	Revalidation : une adresse vérifiée il y a plus de 30 jours est revérifiée avant tout export marqué « prêt à l'envoi » et avant tout envoi vers Campaign Mailer.	M
F-705	Vérification ponctuelle : l'utilisateur colle une liste d'adresses (jusqu'à 1 000) ou importe un CSV d'adresses seules, sans entreprise.	S
F-706	Une adresse signalée en rebond par Campaign Mailer passe <code>invalid</code> avec le motif « rejet constaté à l'envoi ».	P

6.8 Classification des adresses

Type	Préfixes reconnus (exemples)	Priorité pour une candidature
<code>recruitment</code>	recrutement, jobs, careers, carrieres, talent, candidature, emploi, alternance, stage	très haute
<code>hr</code>	rh, hr, drh, people, ressources.humaines	haute
<code>generic</code>	contact, hello, bonjour, info, accueil, office	moyenne
<code>sales</code>	commercial, sales, business, ventes	selon l'usage
<code>press</code>	presse, press, media, communication	selon l'usage
<code>support</code>	support, help, aide, sav	basse

Type	Préfixes reconnus (exemples)	Priorité pour une candidature
personal	forme prenom.nom, p.nom, prenom	à traiter avec prudence (voir 11)
unknown	tout le reste	basse

Le type est déduit automatiquement et reste modifiable. Le contexte de la page aide à trancher : une adresse trouvée sur la page carrières est typée `recruitment` même si son préfixe est générique.

6.9 Score de confiance

Un score de 0 à 100 résume la fiabilité de la donnée. Il mesure la qualité de l'adresse, pas la probabilité d'obtenir une réponse.

Critère	Effet
Trouvée sur le site officiel de l'entreprise	+40
Trouvée dans les mentions légales ou la page contact	+10
Confirmée par un second fournisseur ou une seconde page	+15
Vérification <code>valid</code>	+30
Vérification <code>accept_all</code>	+5
Adresse de rôle pertinente pour les types recherchés	+5
Adresse déduite, non confirmée	plafonnée à 40
Source datant de plus de 12 mois	-15
Vérification <code>unknown</code>	-10
Vérification <code>invalid</code> , <code>disposable</code> ou <code>suppressed</code>	score à 0

Le détail du calcul est affiché au survol du score, critère par critère.

6.10 Bibliothèque

Id	Exigence	Priorité
F-1001	Tableau de bord : entreprises, adresses par statut, imports en cours avec progression réelle, crédits du mois, derniers exports.	M
F-1002	Vue Entreprises : recherche plein texte, filtres (ville, pays, secteur, étiquette, statut de collecte, présence d'une adresse par type), tri, pagination.	M
F-1003	Vue Adresses : adresse, entreprise, type, statut, score, source, date de vérification ; filtres combinables.	M
F-1004	Fiche entreprise : identité, domaine, SIREN, liens, toutes ses adresses regroupées par type avec leurs sources, canaux alternatifs (formulaire, page carrières), historique des traitements, notes.	M
F-1005	Actions en masse : vérifier, revérifier, typer, étiqueter, exclure, exporter, envoyer vers Campaign Mailer, supprimer.	M

Id	Exigence	Priorité
F-1006	Fusion manuelle de deux entreprises reconnues comme doublons.	S
F-1007	Marquer une entreprise « ignorée » ou « déjà contactée ». L'état « déjà contactée » est mis à jour automatiquement par Campaign Mailer quand l'intégration est active.	S
F-1008	Les résultats incertains sont affichés avec leur statut, jamais masqués ni présentés comme vérifiés.	M
F-1009	Interface en français, responsive, utilisable au clavier, conforme au niveau AA des WCAG 2.2.	M
F-1010	Page Contacts avec gestion complète (création, lecture, modification, suppression) de toutes les adresses de la bibliothèque, quelle que soit leur origine (import CSV, collecte, fournisseur, déduction, saisie manuelle).	M
F-1011	Tri de la page Contacts par entreprise, nom du contact, adresse, type, statut de vérification, score, origine et date d'ajout, dans les deux sens, depuis l'en-tête de chaque colonne ou une liste de tri. Les valeurs vides sont toujours placées en fin de liste.	M
F-1012	Recherche plein texte sur l'adresse, le nom, l'entreprise et le domaine, combinable avec les filtres de F-1003. Pagination de 25, 50 ou 100 lignes par page, avec le nombre total de résultats.	M
F-1013	Création manuelle d'un contact : adresse, entreprise (existante ou nouvelle), nom, civilité, type, étiquettes. L'adresse créée suit les contrôles de 6.7 et porte l'origine <code>manual</code> .	M
F-1014	Modification d'un contact : les mêmes champs, avec un nouvel essai de vérification si l'adresse change. L'historique des vérifications de l'ancienne adresse est conservé.	M
F-1015	Suppression d'un contact, unitaire ou en masse, avec confirmation, et option d'ajout à la liste de suppression pour ne plus jamais le collecter.	M

6.11 Exports

Les exports conservent toujours le lien entre chaque adresse et son entreprise. Les lignes sont triées par entreprise, puis par type (recrutement d'abord), puis par score décroissant.

Format	Structure	Usage
CSV « une ligne par adresse »	Colonnes de l'entreprise, puis colonnes de l'adresse (annexe B)	Tableur, CRM, retraitement
CSV « une ligne par entreprise »	Colonnes de l'entreprise, puis <code>best_email</code> , <code>recruitment_emails</code> , <code>hr_emails</code> , <code>generic_emails</code> , séparées par des points-virgules	Vue synthétique, candidature manuelle
XLSX	Quatre onglets : Entreprises, Adresses, Sources, Synthèse. En-têtes figés, filtres activés, une couleur par statut	Analyse et partage
JSON	<code>companies[]</code> , chaque entreprise contenant <code>emails[]</code> , chaque adresse contenant <code>sources[]</code> et <code>verification</code>	Intégration technique
CSV Campaign Mailer	<code>email</code> , <code>contact_name</code> , <code>company_name</code> , <code>salutation</code> : les quatre colonnes que l'import de Campaign Mailer reconnaît	Import direct dans Campaign Mailer

Id	Exigence	Priorité
F-1101	Export de la sélection courante, d'un import, d'une étiquette ou de toute la bibliothèque.	M

Id	Exigence	Priorité
F-1102	Filtre de statut à l'export : <code>valid</code> seulement, <code>valid</code> et <code>accept_all</code> , ou tous sauf les statuts toujours exclus. Réglage par défaut : <code>valid</code> et <code>accept_all</code> .	M
F-1103	Une adresse par entreprise et par type (la meilleure) ou toutes les adresses.	M
F-1104	Les exports volumineux (plus de 2 000 lignes) sont produits en arrière-plan, stockés 7 jours, et signalés par une notification.	M
F-1105	Encodage UTF-8 avec marque d'ordre des octets pour une ouverture correcte dans Excel, séparateur au choix.	M
F-1106	Chaque export est journalisé : qui, quand, quel filtre, combien de lignes.	M

6.12 Intégration avec Campaign Mailer

Les deux applications restent indépendantes : chacune a sa base de données et ses règles. Elles communiquent uniquement par l'API versionnée de Campaign Mailer.

Id	Exigence	Priorité
F-1201	Connexion : l'utilisateur crée un jeton d'intégration dans la page Compte de Campaign Mailer (portées <code>campaigns:write</code> et <code>contacts:write</code>) et le colle dans MailFind. Le jeton est chiffré au repos dans MailFind et n'est jamais réaffiché.	M
F-1202	Envoi d'une sélection vers une nouvelle campagne en brouillon, avec son nom et son type (prospection, alternance, relance, marketing, autre), ou vers un brouillon existant.	M
F-1203	Prévisualisation avant envoi : nombre d'adresses transmises, exclues (et pourquoi), doublons déjà présents dans la campagne.	M
F-1204	Champs transmis : <code>email</code> , <code>contact_name</code> , <code>company_name</code> , <code>salutation</code> , <code>source_url</code> , <code>verification_status</code> , <code>verified_at</code> . Campaign Mailer n'a pas à révérifier une adresse vérifiée depuis moins de 30 jours.	M
F-1205	Revalidation préalable de toute adresse vérifiée depuis plus de 30 jours (F-704).	M
F-1206	Les adresses <code>invalid</code> , <code>disposable</code> , <code>suppressed</code> et <code>unknown</code> ne sont jamais transmises.	M
F-1207	Envoi par lots de 500 au plus, avec une clé d'idempotence par lot : une relance après une coupure ne crée pas de doublon.	M
F-1208	Rapport de synchronisation : transmises, refusées par Campaign Mailer avec leur motif, déjà présentes.	M
F-1209	Une campagne créée depuis MailFind reste un brouillon. Seul l'utilisateur la lance, depuis Campaign Mailer.	M
F-1210	Retour de Campaign Mailer vers MailFind : adresses envoyées (l'entreprise passe « déjà contactée ») et adresses rejetées à l'envoi (passent <code>invalid</code>), par webhook signé.	P
F-1211	Service de vérification pour Campaign Mailer : Campaign Mailer peut appeler <code>POST /v1/verify</code> de MailFind pour vérifier les contacts d'une campagne avant son lancement.	S

Exemple de charge utile transmise à Campaign Mailer :

```
{
  "name": "Alternance développement, Paris, septembre",
  "type": "alternance",
  "contacts": [
    {
      "email": "recrutement@entreprise-exemple.fr",
      "company_name": "Entreprise Exemple",
      "contact_name": null,
      "salutation": "Madame, Monsieur",
      "source_url": "https://www.entreprise-exemple.fr/carrieres",
      "verification_status": "valid",
      "verified_at": "2026-09-22T09:14:03Z"
    }
  ]
}
```

6.13 API publique

Id	Exigence	Priorité
F-1301	API REST sous <code>/v1</code> , en JSON, décrite par un document OpenAPI 3.1 publié et une page de documentation.	M
F-1302	Authentification par clé d'API envoyée dans l'en-tête <code>Authorization: Bearer</code> . Clés créées et révoquées dans la page Compte, affichées une seule fois, stockées hachées, avec portées et date de dernière utilisation.	M
F-1303	Portées: <code>companies:read</code> , <code>companies:write</code> , <code>emails:read</code> , <code>imports:write</code> , <code>verify</code> , <code>exports:write</code> , <code>integrations:write</code> .	M
F-1304	Limitation de débit par clé (60 requêtes par minute par défaut), signalée par les en-têtes <code>RateLimit-*</code> et une réponse 429 avec <code>Retry-After</code> .	M
F-1305	En-tête <code>Idempotency-Key</code> accepté sur toutes les créations, conservé 24 heures.	M
F-1306	Erreurs au format <code>application/problem+json</code> (RFC 9457), avec un code stable.	M
F-1307	Pagination par curseur sur les listes.	M
F-1308	Webhooks: <code>import.completed</code> , <code>import.failed</code> , <code>verification.completed</code> , <code>export.ready</code> . Signature HMAC-SHA256 dans l'en-tête <code>MailFind-Signature</code> avec horodatage, trois nouvelles tentatives avec délai croissant, journal des livraisons.	M
F-1309	Consommation de l'API comptée dans les mêmes quotas que l'interface.	M

Points d'accès :

Méthode	Chemin	Rôle
POST	<code>/v1/imports</code>	Créer un import (fichier CSV ou lignes JSON) et le lancer
GET	<code>/v1/imports/{id}</code>	Statut et progression d'un import
GET	<code>/v1/imports/{id}/results</code>	Entreprises et adresses produites par l'import

Méthode	Chemin	Rôle
POST	/v1/imports/{id}/cancel	Annuler un import
POST	/v1/find	Rechercher les adresses d'une entreprise (nom, domaine ou URL) ; réponse immédiate si en cache, sinon identifiant de tâche
GET	/v1/companies	Lister et filtrer les entreprises
POST	/v1/companies	Créer une entreprise
GET	/v1/companies/{id}	Détail d'une entreprise et de ses adresses
PATCH	/v1/companies/{id}	Modifier une entreprise
DELETE	/v1/companies/{id}	Supprimer une entreprise et ses adresses
POST	/v1/companies/{id}/enrich	Relancer la collecte d'une entreprise
GET	/v1/emails	Lister et filtrer les adresses
PATCH	/v1/emails/{id}	Modifier le type, les étiquettes ou l'exclusion d'une adresse
DELETE	/v1/emails/{id}	Supprimer une adresse
POST	/v1/verify	Vérifier une liste d'adresses (100 en réponse directe, jusqu'à 10 000 en tâche)
GET	/v1/verifications/{id}	Résultat d'une vérification en tâche
POST	/v1/exports	Créer un export filtré
GET	/v1/exports/{id}	Statut et lien de téléchargement temporaire
POST	/v1/integrations/campaign-mailer/push	Envoyer une sélection vers Campaign Mailer
GET	/v1/usage	Crédits et consommation de la période
GET, POST, DELETE	/v1/webhooks	Gérer les abonnements aux webhooks

6.14 Quotas, crédits et coûts

Id	Exigence	Priorité
F-1401	Quotas par utilisateur et par mois : entreprises traitées, pages explorées, recherches fournisseur, vérifications de boîte, exports volumineux. Valeurs fixées en Phase 0 et modifiables par l'administrateur.	M
F-1402	Estimation du coût avant tout traitement de plus de 20 entreprises, avec confirmation obligatoire au-delà d'un seuil choisi par l'utilisateur.	M
F-1403	Arrêt propre d'un import quand un quota est atteint : les entreprises restantes passent « en attente de quota » et reprennent au renouvellement ou sur décision de l'utilisateur.	M
F-1404	Compteur par fournisseur, par utilisateur et par import, consultable.	M
F-1405	Plafond global de dépense par fournisseur et par mois, qui suspend les appels payants pour tous les utilisateurs quand il est atteint et alerte l'administrateur.	M

6.15 Notifications

Id	Exigence	Priorité
F-1501	Notification dans l'application à la fin d'un import, d'une vérification en tâche ou d'un export.	M
F-1502	Email récapitulatif à la fin d'un import long (plus de 10 minutes), désactivable.	S

6.16 Administration

Id	Exigence	Priorité
F-1601	Tableau d'administration : utilisateurs, consommation, coûts par fournisseur, taux d'erreur par fournisseur, files de tâches.	M
F-1602	Activation ou désactivation d'un fournisseur sans redéploiement.	M
F-1603	Gestion de la liste globale de domaines exclus (sites ayant demandé à ne pas être explorés).	M
F-1604	Consultation du journal d'audit.	M

7. Exigences non fonctionnelles

Domaine	Exigence
Performance	Pages de l'interface interactives en moins de 2 secondes sur une connexion 4G. API en lecture sous 300 ms au 95e centile.
Débit de traitement	100 entreprises en profondeur standard en moins de 15 minutes, sans dépasser une requête par seconde et par domaine.
Disponibilité	99,5 % mensuels pour l'interface et l'API. Un traitement en cours survit au redémarrage d'un service.
Montée en charge	Les traitements passent par une file de tâches ; la capacité augmente en ajoutant des processus de traitement, sans changement de code.
Fiabilité	Toute tâche est idempotente et peut être rejouée sans double consommation de crédit ni doublon de données.
Accessibilité	WCAG 2.2 niveau AA : navigation au clavier, contrastes, libellés, annonces des changements d'état.
Compatibilité	Deux dernières versions de Chrome, Edge, Firefox et Safari, sur ordinateur et mobile.
Langue	Interface et messages en français. Codes d'erreur de l'API en anglais, stables.
Maintenabilité	TypeScript strict de bout en bout, couverture de tests d'au moins 70 % au global et 90 % dans les services métier.
Réversibilité	Export complet des données d'un utilisateur en JSON à tout moment.

8. Architecture technique

8.1 Choix de la pile

La pile reprend celle de Campaign Mailer, pour réutiliser les pratiques, les services hébergés et les outils déjà maîtrisés.

Couche	Choix	Raison
Langage	TypeScript strict	Plusieurs machines à états (import, collecte, vérification) : une faute de frappe sur un statut doit échouer à la compilation.
Interface	React 19, Vite, Tailwind CSS, React Router	Identique à Campaign Mailer, un seul système de conception à tenir.
API	Node.js 24, Express 5, validation par schémas zod	Identique à Campaign Mailer. Les schémas produisent aussi le document OpenAPI.
Base de données	PostgreSQL (Neon), migrations SQL versionnées avec retour arrière	Données relationnelles, recherche plein texte native.
File de tâches	BullMQ sur Redis	Nouvelles tentatives, délais, limitation de débit par groupe (par domaine, par fournisseur).
Collecte	<code>fetch</code> de Node, Cheerio pour l'analyse HTML, un analyseur <code>robots.txt</code> conforme à la RFC 9309	Léger, sans navigateur. Le rendu JavaScript est reporté après le MVP.
DNS	<code>node:dns/promises</code>	Contrôles MX et DNS sans service tiers.
Stockage de fichiers	Cloudflare R2, compatible S3	Imports d'origine et exports, liens de téléchargement temporaires.
Exports XLSX	ExcelJS	Onglets, styles, filtres, écriture en flux.
Authentification	Passport.js, stratégie Google OAuth 2.0, sessions en Redis	Identique à Campaign Mailer, portées non sensibles uniquement.
Observabilité	pino (journaux JSON), Sentry	Identique à Campaign Mailer.
Hébergement	Vercel pour l'interface, Railway pour l'API et les processus de traitement	Identique à Campaign Mailer, même région que les données.

8.2 Décision ouverte à trancher en Phase 0

L'offre gratuite d'Upstash compte chaque commande Redis. Campaign Mailer tient dans cette offre grâce à un seul processus qui dort quand rien n'est prévu. MailFind aura plusieurs files actives pendant les imports, et dépassera cette offre. Trois options, à arbitrer en Phase 0 : Upstash à l'usage, Redis hébergé chez Railway, ou file de tâches sur PostgreSQL. La recommandation est Upstash à l'usage, pour garder BullMQ et le même client que Campaign Mailer, avec un budget mensuel plafonné.

8.3 Composants

Composant	Rôle
Application web	Tous les écrans. Lit le CSV dans le navigateur pour la correspondance des colonnes.
API	Authentification, bibliothèque, imports, exports, API publique, webhooks sortants. N'explore jamais un site.
Processus de collecte	Identification des entreprises et exploration des sites. Limitation par domaine.
Processus d'enrichissement et de vérification	Appels aux fournisseurs, contrôles DNS, calcul des scores. Limitation par fournisseur.
Processus d'export et de synchronisation	Production des fichiers, envoi vers Campaign Mailer, livraison des webhooks.

8.4 Déroulé d'un import

1. L'API enregistre l'import et ses lignes, puis place une tâche `import.plan`.
2. `import.plan` normalise, dédouble et crée une tâche `company.identify` par entreprise nouvelle.
3. `company.identify` confirme le domaine, puis place `company.crawl`.
4. `company.crawl` explore les pages ciblées et enregistre adresses et sources, puis place `company.enrich` si le résultat est insuffisant, sinon `company.verify`.
5. `company.enrich` interroge les fournisseurs dans l'ordre de repli, puis génère les candidates si besoin, puis place `company.verify`.
6. `company.verify` applique les contrôles, calcule les scores et marque l'entreprise « traitée ».
7. Quand toutes les entreprises de l'import sont traitées, l'import passe « terminé », le rapport est produit et les webhooks sont émis.

Chaque tâche porte un identifiant dérivé de l'entreprise et de l'étape : la même étape ne peut pas être en file deux fois. Chaque appel payant est précédé d'une réservation de crédit et suivi de sa confirmation, pour qu'une tâche rejouée après une coupure ne paie pas deux fois.

9. Modèle de données

Table	Champs principaux
users	id, google_id, email, name, terms_version, created_at, deleted_at
imports	id, user_id, filename, storage_key, settings (profondeur, types, fournisseurs), total_rows, processed_rows, status, estimated_credits, used_credits, created_at, completed_at
import_rows	id, import_id, line, raw (JSON), company_id, status, error
companies	id, user_id, name, normalized_name, legal_name, domain, website_url, careers_url, siren, city, country, industry, employee_range, linkedin_url, phone, contact_form_url, crawl_status, domain_confidence, tags, notes, attributes (JSON), last_enriched_at, created_at
emails	id, company_id, user_id, address, normalized_address, local_part, type, origin (found , provider , deduced , imported), status, score, excluded, excluded_reason, last_verified_at, created_at
email_sources	id, email_id, kind (website , provider , import , deduction), url, provider, extraction_method, context_excerpt, discovered_at
verifications	id, email_id, level, status, sub_status, reason, provider, raw_reference, verified_at
pipeline_jobs	id, import_id, company_id, step, status, attempts, error, started_at, completed_at
provider_calls	id, user_id, import_id, provider, operation, domain, credits, cached, status, created_at
provider_cache	provider, operation, key, response (JSON chiffré), expires_at
page_cache	url, status_code, content_hash, fetched_at, expires_at
exports	id, user_id, format, filters (JSON), row_count, storage_key, status, expires_at, created_at
api_keys	id, user_id, name, prefix, key_hash, scopes, last_used_at, revoked_at, created_at
webhooks	id, user_id, url, events, secret (chiffré), active, created_at
webhook_deliveries	id, webhook_id, event, payload_hash, status_code, attempts, next_attempt_at, delivered_at
integrations	id, user_id, kind (campaign_mailer), base_url, token (chiffré), status, last_sync_at
sync_runs	id, integration_id, campaign_ref, sent, refused, duplicates, idempotency_key, created_at
suppressions	id, user_id, address_hash, reason, source, created_at
excluded_domains	domain, reason, requested_at
audit_events	id, user_id, action, entity, entity_id, metadata (JSON, sans adresse en clair), created_at

Contraintes essentielles : une adresse unique par entreprise (company_id , normalized_address) ; une entreprise unique par utilisateur et par domaine ; les statuts sont des types énumérés vérifiés par la base ; chaque migration a son retour arrière.

10. Sécurité

Id	Exigence
S-01	Secrets (clés des fournisseurs, jetons Campaign Mailer, secrets de webhooks, clés d'API personnelles) chiffrés au repos en AES-256-GCM, avec rotation de clé documentée.
S-02	Clés d'API de MailFind stockées hachées ; seul un préfixe est affiché pour les reconnaître.
S-03	Aucun secret, aucune adresse et aucun jeton dans les journaux, les messages d'erreur ou les rapports Sentry.
S-04	Toute route vérifie que la ressource appartient à l'utilisateur, dans la requête SQL elle-même : une ressource d'un autre compte répond 404.
S-05	Protection contre la falsification de requête côté serveur dans le moteur de collecte : seules les adresses publiques sont visitées ; adresses IP privées, locales, de lien local et de métadonnées de fournisseurs cloud refusées, y compris après résolution DNS et après redirection.
S-06	Le contenu des pages explorées n'est jamais rendu tel quel dans l'interface. Les extraits de contexte sont échappés.
S-07	Les valeurs des fichiers CSV sont traitées comme hostiles : échappées à l'affichage, et neutralisées à l'export contre l'injection de formules tableur (cellules commençant par <code>=</code> , <code>+</code> , <code>-</code> , <code>@</code>).
S-08	Limitation de débit sur l'authentification, l'API publique et les imports.
S-09	En-têtes de sécurité HTTP, cookies <code>httpOnly</code> , <code>secure</code> et <code>sameSite=lax</code> , protection CSRF sur les formulaires de l'interface.
S-10	Webhooks sortants signés ; les URL de webhook sont soumises à la même protection que S-05.
S-11	Revue de sécurité du code avant chaque mise en production, et analyse des dépendances.

11. Conformité juridique et protection des données

Cette section fixe des règles de conception. Elle ne remplace pas l'avis d'un juriste, à solliciter avant l'ouverture au public.

11.1 Nature des données

Une adresse de rôle d'une personne morale (`contact@` , `recrutement@`) n'identifie en principe personne. Une adresse nominative (`prenom.nom@`) est une donnée personnelle au sens du RGPD, même quand elle est professionnelle et publiée. MailFind privilégie donc les adresses de rôle et traite les adresses nominatives avec des règles plus strictes.

11.2 Rôles

- Pour les données des comptes utilisateurs, MailFind est responsable de traitement.
- Pour les adresses collectées à la demande d'un utilisateur, l'utilisateur détermine la finalité (candidature, prospection) : il est responsable de traitement et MailFind agit en sous-traitant, selon des conditions d'utilisation qui le précisent (article 28 du RGPD).

11.3 Règles appliquées par le produit

Id	Règle
R-01	Minimisation : seules l'adresse, sa source et les données de l'entreprise sont collectées. Aucun profil de personne, aucune donnée de réseau social.
R-02	Provenance : la source de chaque donnée est conservée et exportée, pour permettre d'informer la personne concernée de l'origine de ses données.
R-03	Information des personnes : quand un utilisateur contacte une personne dont l'adresse nominative a été collectée, il doit l'informer au plus tard lors de la première communication (article 14 du RGPD). MailFind le rappelle à l'export d'adresses nominatives et fournit une mention type.
R-04	Opposition : liste de suppression par utilisateur, respectée par toutes les fonctions et transmise à Campaign Mailer. Une adresse supprimée n'est plus jamais collectée pour cet utilisateur.
R-05	Effacement : suppression définitive d'une adresse, d'une entreprise, d'un import ou d'un compte, sources et vérifications comprises.
R-06	Conservation : adresses et sources non consultées ni exportées depuis 12 mois supprimées automatiquement ; journaux techniques 90 jours ; journal d'audit 12 mois.
R-07	Retrait des sites : une page publique explique ce que fait l'agent de collecte et permet à un site de demander son exclusion, appliquée à tous les utilisateurs.
R-08	Respect des sites : <code>robots.txt</code> , débit limité, aucune authentification, aucun contournement de protection (F-403 à F-407).
R-09	Respect des fournisseurs : utilisation des API officielles dans le cadre de leurs conditions, sans revente des résultats bruts.
R-10	Prospection : rappel dans l'interface des règles de la CNIL sur la prospection électronique entre professionnels (message en rapport avec la fonction du destinataire, information et possibilité de s'opposer à chaque envoi).
R-11	Registre des traitements tenu à jour, liste des sous-traitants (hébergeurs, fournisseurs d'enrichissement) publiée dans la politique de confidentialité.

Id	Règle
R-12	Analyse d'impact relative à la protection des données menée avant l'ouverture au public, compte tenu de la collecte à grande échelle de données publiques.

12. Exploitation et observabilité

Élément	Exigence
Journaux	JSON structurés, identifiant de requête et identifiant de tâche sur chaque ligne, adresses et jetons exclus.
Erreurs	Sentry sur l'API, les processus de traitement et l'interface, données personnelles retirées avant l'envoi.
Santé	<code>/health</code> (le processus répond) et <code>/ready</code> (base, Redis, files, fournisseurs principaux).
Alertes	Taux d'échec d'un fournisseur au-dessus de 20 % sur une heure, file bloquée depuis 15 minutes, plafond de dépense atteint à 80 % puis 100 %, processus de traitement silencieux depuis 15 minutes.
Sauvegardes	Sauvegarde quotidienne de la base, restauration testée avant la mise en production et consignée.
Documentation	Architecture, procédures d'incident, règles de collecte et de vérification, guide de l'API, guide de prise en main.

13. Tests et recette

13.1 Stratégie

- Tests unitaires sur les règles pures : normalisation, extraction des adresses, classification, score, génération des candidates, statuts de vérification.
- Tests d'intégration contre une base PostgreSQL de test, dans un schéma jetable par exécution.
- Tests du moteur de collecte contre un jeu de sites de test servis localement (pages contact, mentions légales, adresses masquées, `robots.txt` restrictif, redirections, pages lourdes).
- Fournisseurs simulés en test, avec leurs réponses documentées, y compris les erreurs de quota.
- Tests de contrat de l'API contre le document OpenAPI, et tests de contrat partagés avec Campaign Mailer.
- Parcours complet de bout en bout dans un navigateur : connexion, import, suivi, export, envoi vers Campaign Mailer.

13.2 Critères d'acceptation du MVP

N°	Critère
A1	Un CSV de 100 entreprises réelles (noms seuls, domaines seuls, URL mélangés) est traité de bout en bout sans intervention, en moins de 15 minutes.
A2	Le taux de couverture de l'indicateur 2.2 est atteint sur ce jeu.
A3	Aucune adresse <code>unverified</code> , <code>unknown</code> , <code>invalid</code> , <code>disposable</code> ou <code>suppressed</code> n'apparaît dans un export « prêt à l'envoi » ni dans un envoi vers Campaign Mailer.
A4	Chaque adresse exportée a au moins une source avec URL ou fournisseur.
A5	Un import interrompu par un redémarrage reprend et se termine, sans doublon d'entreprise ni double consommation de crédit.
A6	Un site dont le <code>robots.txt</code> interdit l'agent n'est pas visité.
A7	L'envoi vers Campaign Mailer crée un brouillon importable et lançable, relancé deux fois sans créer de doublon.
A8	L'API répond conformément au document OpenAPI sur tous les points d'accès.
A9	Une demande d'effacement supprime l'adresse, ses sources et ses vérifications, et l'adresse n'est plus collectée ensuite.
A10	La revue de sécurité ne laisse aucune anomalie critique ou haute ouverte.

14. Planning et jalons

Le découpage détaillé, tâche par tâche, est dans `ROADMAP.md`. Les jalons :

Jalon	Contenu	Durée cible
J0	Fondations et décisions gelées	3 jours
J1	Comptes, socle et import CSV	8 jours
J2	Identification et collecte sur les sites	8 jours
J3	Fournisseurs, adresses candidates et vérification	8 jours
J4	Bibliothèque et exports	6 jours
J5	API publique et intégration Campaign Mailer	7 jours
J6	Sécurité, conformité, quotas, tests et documentation	8 jours
J7	Mise en production et bêta	4 jours

Total du MVP : environ 52 jours ouvrés pour une personne.

15. Risques

Risque	Probabilité	Impact	Parade
Faible couverture sur les sites qui ne publient aucune adresse	élevée	moyen	Repli sur les fournisseurs et les adresses candidates vérifiées, canaux alternatifs (formulaire, page carrières) présentés.
Coût des fournisseurs supérieur aux prévisions	moyenne	élevé	Cache de 30 jours, estimation avant lancement, plafonds par utilisateur et global.
Blocage de l'agent de collecte par des sites	moyenne	moyen	Débit bas, agent identifié, respect de robots.txt, aucune tentative de contournement.
Plainte d'une personne ou d'un site	faible	élevé	Provenance conservée, retrait des sites, liste de suppression, effacement immédiat, analyse d'impact.
Adresses accept_all présentées comme fiables	moyenne	moyen	Statut distinct, exclusion par défaut des envois « prêts », score plafonné.
Dérive du périmètre vers les fonctions post-MVP	élevée	élevé	Aucune tâche du bloc post-MVP avant la validation de la mise en production.
Changement des conditions ou de l'API d'un fournisseur	moyenne	moyen	Adaptateurs indépendants, second fournisseur prêt à activer.
Dépassement des quotas Redis	élevée	faible	Décision de la Phase 0 (8.2), budget plafonné.

16. Glossaire

Terme	Définition
Adresse de rôle	Adresse attachée à une fonction plutôt qu'à une personne : contact@, recrutement@.
Adresse candidate, déduite	Adresse générée par MailFind comme probable, jamais trouvée publiée.
Accept-all	Domaine dont le serveur accepte toute adresse, ce qui empêche de confirmer une boîte précise.
Collecte	Exploration des pages publiques d'un site pour y relever des adresses.
Enrichissement	Complément d'information obtenu auprès d'un fournisseur par API.
Enregistrement MX	Entrée DNS qui désigne les serveurs de messagerie d'un domaine.
Profondeur	Nombre et nature des pages explorées par entreprise.
Rebond	Message refusé par le serveur du destinataire.
Source	Preuve de l'origine d'une adresse : URL de page, fournisseur, import ou déduction.
Suppression	Adresse qu'un utilisateur ne veut plus jamais collecter ni transmettre.

17. Annexes

Annexe A : exemple de fichier d'import

```
entreprise,site,carrieres,ville,etiquettes
Doctolib,doctolib.fr,,Paris,alternance;sante
Entreprise Exemple,https://www.entreprise-exemple.fr,https://www.entreprise-exemple.fr/carrieres,Lyon,alternance
Startup Sans Site,,,Nantes,
,agence-web-exemple.fr,,Bordeaux,prospection
```

La troisième ligne sera identifiée par l'API Recherche d'entreprises, puis son site recherché. La quatrième, sans nom, prendra le nom trouvé sur le site.

Annexe B : structure de l'export « une ligne par adresse »

```
company_id, company_name, domain, website_url, careers_url, siren, city, country,
industry, company_tags, email, email_type, origin, verification_status,
verification_reason, verified_at, score, source_kind, source_url, provider,
discovered_at, email_tags, notes
```

Annexe C : réponse de `POST /v1/find`

```
{
  "company": {
    "id": "cmp_01J9Z3",
    "name": "Entreprise Exemple",
    "domain": "entreprise-exemple.fr",
    "careers_url": "https://www.entreprise-exemple.fr/carrieres"
  },
  "emails": [
    {
      "address": "recrutement@entreprise-exemple.fr",
      "type": "recruitment",
      "origin": "found",
      "status": "valid",
      "score": 90,
      "verified_at": "2026-09-22T09:14:03Z",
      "sources": [
        {
          "kind": "website",
          "url": "https://www.entreprise-exemple.fr/carrieres",
          "discovered_at": "2026-09-22T09:13:41Z"
        }
      ]
    },
    {
      "address": "rh@entreprise-exemple.fr",
      "type": "hr",
      "origin": "deduced",
      "status": "accept_all",
      "score": 35,
      "verified_at": "2026-09-22T09:14:05Z",
      "sources": [{ "kind": "deduction", "discovered_at": "2026-09-22T09:14:02Z" }]
    }
  ],
  "alternatives": {
    "contact_form_url": "https://www.entreprise-exemple.fr/contact"
  },
  "cached": false
}
```

Annexe D : préfixes de rôle utilisés pour les adresses candidates

Type	Préfixes, par ordre d'essai
recruitment	recrutement, jobs, careers, carrieres, rh.recrutement, talent, candidature, emploi, alternance, stage
hr	rh, hr, drh, people

Type	Préfixes, par ordre d'essai
generic	contact, hello, bonjour, info
sales	commercial, sales, business
press	presse, press, communication